



SKRIPSI

**ANALISIS PERBANDINGAN METODE CLAHE
DAN CONTRAST STRETCHING DALAM
MENINGKATKAN KUALITAS CITRA X-RAY**

AGUS BISANA PUTRA

NPM 21081010125

DOSEN PEMBIMBING

**KEMENTERIAN PENDIDIKAN, KEBUDAYAAN, RISET, DAN TEKNOLOGI
UNIVERSITAS PEMBANGUNAN NASIONAL VETERAN JAWA TIMUR
FAKULTAS ILMU KOMPUTER
PROGRAM STUDI INFORMATIKA
SURABAYA
2024**



SKRIPSI

**ANALISIS PERBANDINGAN METODE CLAHE
DAN CONTRAST STRETCHING DALAM
MENINGKATKAN KUALITAS CITRA X-RAY**

AGUS BISANA PUTRA

NPM 21081010125

DOSEN PEMBIMBING

**KEMENTERIAN PENDIDIKAN, KEBUDAYAAN, RISET, DAN TEKNOLOGI
UNIVERSITAS PEMBANGUNAN NASIONAL VETERAN JAWA TIMUR
FAKULTAS ILMU KOMPUTER
PROGRAM STUDI INFORMATIKA
SURABAYA
2024**

LEMBAR PENGESAHAN

ANALISIS PERBANDINGAN METODE CLAHE DAN CONTRAST STRETCHING DALAM MENINGKATKAN KUALITAS CITRA X-RAY

Oleh:

AGUS BISANA PUTRA

NPM. 21081010125

Telah dipertahankan dihadapan dan diterima oleh Tim Penguji Skripsi Prodi Informatika Fakultas Ilmu Komputer Universitas Pembangunan Nasional Veteran Jawa Timur pada tanggal.....

Menyetujui,

Nama Dosen

NIP / NPT

..... (Pembimbing I)

Nama Dosen

NIP / NPT

..... (Pembimbing II)

Nama Dosen

NIP / NPT

..... (Ketua Penguji)

Nama Dosen

NIP / NPT

..... (Anggota Penguji II)

Mengetahui,

Dekan Fakultas Ilmu Komputer

Prof. Dr. Ir. Novirina Hendrasarie, MT

NIP. 19681126 199403 2 001

LEMBAR PERSETUJUAN

ANALISIS PERBANDINGAN METODE CLAHE DAN CONTRAST STRETCHING DALAM MENINGKATKAN KUALITAS CITRA X-RAY

Oleh:

AGUS BISANA PUTRA

NPM. 21081010125

Telah disetujui untuk mengikuti Ujian Skripsi

Menyetujui,

Dosen Pembimbing I

Dosen Pembimbing II

Nama Dosen

NIP

Nama Dosen

NIP

Koordinator Skripsi

Prodi Informatika Fakultas Ilmu Komputer

Andreas Nugroho Sihananto, S. Kom., M. Kom.

NIP. 199004122024061003

SURAT PERNYATAAN ORISINALITAS

Yang bertanda tangan di bawah ini:

Nama mahasiswa / NPM : Agus Bisana Putra / 21081010125
Program Studi : Informatika
Dosen Pembimbing :

dengan ini menyatakan bahwa Skripsi dengan judul “**ANALISIS PERBANDINGAN METODE CLAHE DAN CONTRAST STRETCHING DALAM MENINGKATKAN KUALITAS CITRA X-RAY**” adalah hasil karya sendiri, bersifat orisinal, dan ditulis dengan mengikuti kaidah penulisan ilmiah. Bilamana di kemudian hari ditemukan ketidaksesuaian dengan pernyataan ini, maka saya bersedia menerima sanksi sesuai dengan ketentuan yang berlaku di Universitas Pembangunan Nasional Veteran Jawa Timur.

Surabaya,

Mahasiswa

(Agus Bisana Putra)

NPM. 21081010125

ABSTRAK

ABSTRACT

KATA PENGANTAR

DAFTAR ISI

DAFTAR TABEL

DAFTAR GAMBAR

BAB I

PENDAHULUAN

1.1 Latar Belakang

Implementasi pengolahan citra pada berbagai bidang didukung dengan kemajuan teknologi dan meningkatnya kemampuan komputasi. Pada bidang kesehatan, pengolahan citra medis berguna untuk mendeteksi penyakit maupun analisa kondisi medis lainnya (Supiyandi dkk., 2024).

Citra medis merupakan gambar dua dimensi yang menunjukkan bagian dalam dari tubuh manusia. Pengambilan citra medis bertujuan agar tenaga medis dapat mendeteksi dan menganalisa penyakit pasien. Terdapat beberapa metode dalam memperoleh citra medis, seperti *X-Ray*, *Computed Tomography* (CT-Scan), *Magnetic Resonance Imaging* (MRI), *Ultrasonography* (USG), *Nuclear Medicine*, dan *Endoscopy* (Kusuma & Kusumadewi, 2020). Sinar X-Ray adalah salah satu teknologi yang kerap digunakan untuk klasifikasi atau deteksi penyakit, memudahkan ahli radiologi dalam diagnosa keadaan tubuh dalam pasien (Effendy dkk., 2024).

Terdapat beberapa permasalahan yang kerap terjadi pada citra medis yang disebabkan oleh *noise* acak, fenomena *artifact* yang disebabkan oleh perbedaan intensitas, serta efek volume parsial (Kusuma & Kusumadewi, 2020). Oleh karena itu, peningkatan kualitas citra X-Ray dibutuhkan guna membantu dokter atau praktisi kesehatan dalam menganalisa hasil X-Ray (Putra dkk., 2022).

Penelitian ini bertujuan untuk membandingkan kinerja dua metode peningkatan kualitas citra, yaitu *Contrast Limited Adaptive Histogram Equalization* (CLAHE) dan *Contrast Stretching*. Hasil peningkatan kualitas citra dievaluasi berdasarkan parameter SNR, SSIM, dan Entropi. Oleh karena itu, diharapkan penelitian ini dapat memberikan kontribusi dalam penggunaan metode peningkatan kualitas citra yang paling efektif pada citra medis, spesifik pada X-Ray.

1.2 Rumusan Masalah

1. Bagaimana perbandingan kinerja metode CLAHE dan Contrast Stretching dalam meningkatkan kualitas citra X-ray?
2. Sejauh mana metode CLAHE dan Contrast Stretching mampu mengurangi noise pada citra X-ray berdasarkan metrik SNR?

3. Bagaimana efektivitas kedua metode dalam mempertahankan detail struktur citra berdasarkan metrik SSIM dan Entropy?

1.3 Tujuan

1. Membandingkan kinerja metode CLAHE dan Contrast Stretching dalam meningkatkan kualitas citra X-ray.
2. Mengevaluasi kemampuan kedua metode dalam mengurangi noise pada citra X-ray menggunakan metrik SNR.
3. Menilai efektivitas metode CLAHE dan Contrast Stretching dalam mempertahankan detail struktur citra menggunakan metrik SSIM dan Entropy.

1.4 Manfaat

1. Memberikan kontribusi bagi pengembangan ilmu pengetahuan dalam bidang pengolahan citra digital, khususnya pada pencitraan medis.
2. Membantu tenaga medis dalam memilih metode pengolahan citra yang lebih efektif untuk analisis citra X-ray.

1.5 Batasan Masalah

1. Penelitian hanya berfokus pada dua metode peningkatan kualitas citra, yaitu CLAHE dan Contrast Stretching.
2. Objek citra yang digunakan dalam penelitian ini terbatas pada citra X-ray.
3. Evaluasi kinerja metode dilakukan menggunakan tiga metrik: SNR, SSIM, dan Entropy.
4. Penelitian tidak mencakup analisis klinis atau pengujian langsung pada pasien, tetapi berfokus pada evaluasi kualitas citra secara teknis.

BAB II

TINJAUAN PUSTAKA

2.1 Penelitian Terdahulu

Penelitian terdahulu pada jurnal yang berjudul “Penerapan Metode Contrast Stretching, Histogram Equalization dan Adaptive Histogram Equalization untuk Meningkatkan Kualitas Citra Medis MRI” oleh (Kusuma & Kusumadewi, 2020). Adapun tujuan penelitian tersebut untuk membandingkan tiga metode peningkatan kualitas citra, yaitu metode *Contrast Stretching*, *Histogram Stretching*, dan *Adaptive Histogram Equalization*. Hasilnya menunjukkan bahwa metode *Contrast Stretching* menghasilkan kualitas citra MRI yang lebih baik dibandingkan dua metode lainnya.

Penelitian terdahulu pada jurnal yang berjudul “Pengaruh Contrast Limited Adaptive Histogram Equalization Dalam Klasifikasi CT-Scan Tumor Ginjal Menggunakan Deep Learning” oleh Jannata, dkk. (2020). Adapun tujuan penelitian tersebut untuk membandingkan hasil dataset non-CLAHE dan CLAHE dalam klasifikasi citra ginjal normal dan tumor dengan menggunakan *CNN MobileNetV2*. Hasilnya menunjukkan bahwa penggunaan CLAHE terbukti meningkatkan performa model dalam mengklasifikasikan citra CT-scan.

2.2 Citra Medis

Citra medis adalah gambar yang dihasilkan dari berbagai modalitas pencitraan medis, seperti sinar-X, MRI, CT scan, dan ultrasonografi, yang digunakan untuk mendiagnosis dan memantau kondisi kesehatan pasien. Kualitas citra medis sangat penting karena mempengaruhi akurasi diagnosis. Oleh karena itu, teknik peningkatan kualitas citra, seperti contrast stretching dan CLAHE, sering diterapkan untuk meningkatkan visibilitas detail dalam citra medis. (Kusuma & Kusumadewi, 2020)

2.3 CLAHE

CLAHE adalah metode pengolahan citra yang digunakan untuk meningkatkan kontras citra, terutama pada citra medis yang seringkali memiliki kontras rendah. Teknik ini mengadaptasi histogram lokal di dalam citra dan membatasi peningkatan kontras agar tidak menimbulkan noise yang berlebihan.

CLAHE sangat berguna pada citra medis seperti radiografi dan MRI, di mana kontras gambar sangat penting untuk mendeteksi kelainan (Zhang et al., 2019).

2.4 Contrast Stretching

Contrast stretching adalah teknik peningkatan kontras yang memperluas rentang intensitas piksel dalam citra sehingga distribusi intensitas menjadi lebih luas. Metode ini dapat meningkatkan kualitas visual citra medis dengan membuat detail yang sebelumnya kurang terlihat menjadi lebih jelas (Erwin & Ningsih, 2020).

2.5 SNR

SNR adalah rasio antara kekuatan sinyal dan kekuatan noise pada citra. Dalam konteks citra medis, SNR yang tinggi mengindikasikan kualitas citra yang baik dengan noise minimal, sementara SNR rendah mengindikasikan citra dengan banyak gangguan. SNR digunakan untuk mengevaluasi kualitas citra yang dihasilkan oleh perangkat medis dan untuk mengoptimalkan teknik pengolahan citra agar noise dapat dikurangi tanpa mengorbankan informasi penting (Sánchez et al., 2017).

2.6 SSIM

SSIM adalah metrik yang digunakan untuk mengukur kesamaan antara dua citra dengan mempertimbangkan luminans, kontras, dan struktur. SSIM sangat penting dalam evaluasi kualitas citra medis setelah dilakukan pemrosesan, seperti penguatan atau kompresi, karena dapat mengukur degradasi kualitas citra yang mungkin tidak terlihat secara langsung (Wang et al., 2004).

2.7 Entropy

Entropy adalah ukuran ketidakpastian atau keragaman dalam citra. Dalam pengolahan citra medis, nilai entropy dapat digunakan untuk menilai tingkat kompleksitas atau detail dalam citra. Citra dengan nilai entropy tinggi memiliki lebih banyak informasi, sedangkan citra dengan nilai entropy rendah cenderung lebih sederhana dan mungkin mengindikasikan hilangnya detail yang penting dalam proses pengolahan (Zhang & Lu, 2018).

BAB III

METODOLOGI

3.1 Alur Penelitian

1. Tahap Persiapan:

- Mengidentifikasi kebutuhan penelitian.
- Mengumpulkan dataset citra X-ray medis dari sumber yang kredibel.
- Memastikan kelengkapan perangkat keras dan perangkat lunak yang akan digunakan (misalnya MATLAB, Python, atau perangkat lunak lainnya).

2. Tahap Preprocessing:

- Melakukan normalisasi citra untuk memastikan keseragaman ukuran dan format.
- Mengeliminasi citra yang memiliki artefak atau kualitas sangat rendah untuk menjaga konsistensi data.

3. Tahap Penerapan Metode Pengolahan Citra:

- Menerapkan metode **CLAHE** pada citra X-ray sesuai parameter yang telah ditentukan (misalnya ukuran tile dan clip limit).
- Menerapkan metode **Contrast Stretching** pada citra X-ray dengan merentangkan rentang intensitas piksel.

4. Tahap Evaluasi Kinerja:

- Mengukur kualitas hasil pengolahan citra dengan metrik berikut:
 - **SNR (Signal-to-Noise Ratio)** untuk mengevaluasi tingkat pengurangan noise.
 - **SSIM (Structural Similarity Index Measure)** untuk mengevaluasi kesesuaian struktur citra hasil pengolahan dengan citra asli.
 - **Entropy** untuk mengukur informasi yang terkandung dalam citra hasil pengolahan.
- Melakukan analisis statistik untuk membandingkan hasil dari kedua metode.

5. Tahap Analisis dan Interpretasi:

- Menganalisis data hasil evaluasi berdasarkan metrik yang digunakan.
- Membandingkan kelebihan dan kelemahan masing-masing metode dalam meningkatkan kualitas citra X-ray medis.
- Menarik kesimpulan dari hasil penelitian.

DAFTAR PUSTAKA

- Angga, W., Kusuma, W., & Kusumadewi, A. (2020). PENERAPAN METODE CONTRAST STRETCHING, HISTOGRAM EQUALIZATION DAN ADAPTIVE HISTOGRAM EQUALIZATION UNTUK MENINGKATKAN KUALITAS CITRA MEDIS MRI. *Jurnal SIMETRIS*, 11(1).
- Erwin, & Ningsih, D. R. (2020). Improving Retinal Image Quality Using the Contrast Stretching, Histogram Equalization, and CLAHE Methods with Median Filters. *International Journal of Image, Graphics and Signal Processing*, 12(2), 30–41. <https://doi.org/10.5815/ijigsp.2020.02.04>
- Jannata, N., Yanto, F., Handayani, L., Pandu, E., & Kurnia, C. (n.d.). *Pengaruh Contrast Limited Adaptive Histogram Equalization Dalam Klasifikasi CT-Scan Tumor Ginjal Menggunakan Deep Learning*. 9(1), 2024.
- Sachio, A., Susilo Effendy, R., Alfin, M., Abidin, G., Kusuma, R. R., Ramadhan, R. W., & Rosyani, P. (n.d.). *Klasifikasi Penyakit Paru-Paru Berbasis Pengolahan Citra X-Ray Menggunakan Convolutional Neural Network*. <https://jurnalmahasiswa.com/index.php/biikma>
- Sahi, A. (2020). *APLIKASI TEST POTENSI AKADEMIK SELEKSI SARINGAN MASUK LP3I BERBASIS WEB ONLINE MENGGUNAKAN FRAMEWORK CODEIGNITER* (Vol. 7, Issue 1). <http://www.php.net>.
- Supiyandi Supiyandi, Muhammad Abdul Mujib, Khairul Azis, Rahmat Abdillah, & Salsa Nabila Iskandar. (2024). Penerapan Teknologi Pengolahan Citra dalam Analisis Data Visual pada Tinjauan Komprehensif. *Jurnal Kendali Teknik Dan Sains*, 2(3), 179–187. <https://doi.org/10.59581/jkts-widyakarya.v2i3.3796>

PENERAPAN METODE CONTRAST STRETCHING, HISTOGRAM EQUALIZATION DAN ADAPTIVE HISTOGRAM EQUALIZATION UNTUK MENINGKATKAN KUALITAS CITRA MEDIS MRI

I Wayan Angga Wijaya Kusuma

Fakultas Teknik, Program Studi Teknik Elektro
Universitas Widya Dharma
Email: anggaelectro@yahoo.com

Afriliana Kusumadewi

Fakultas Teknik, Program Studi Teknik Elektro
Universitas Widya Dharma
Email: lina@unwidha.ac.id

ABSTRAK

Citra medis adalah suatu pola atau gambar dua dimensi bagian dalam tubuh manusia yang digunakan oleh ahli kesehatan untuk mendeteksi dan menganalisa penyakit pasien. Citra yang dihasilkan terkadang tidak sesuai dengan hasil yang diharapkan. Hal ini dapat terjadi karena beberapa kemungkinan, misalnya sensitif terhadap kontras, mengalami kekaburan, memiliki noise atau kejernihan tampak, memiliki bercak, dan bagian-bagian detailnya tidak tergambar jelas karena sering terdapat gangguan pada proses pengambilannya. Salah satu citra yang paling sering digunakan adalah citra Magnetic resonance Imaging (MRI). Citra MRI memiliki kemampuan dapat menampilkan detail anatomi obyek secara jelas dalam berbagai potongan (multiplanar) tanpa mengubah posisi pasien. Dokter ataupun peneliti menggunakan citra MRI untuk melakukan analisa ada tidaknya suatu tumor, kanker, atau kelainan pada pasien. Penelitian ini mengusulkan metode Contrast Stretching, Histogram Equalization dan Adaptive Histogram Equalization untuk meningkatkan kualitas citra medis. Citra medis yang digunakan pada penelitian ini adalah citra medis MRI Otak baik kondisi normal ataupun kondisi yang mengalami lesi (gangguan). Dari hasil kualitas citra dan analisa kuantitatif menunjukkan bahwa metode contrast stretching menghasilkan hasil kualitas citra MRI jauh lebih baik dibandingkan dengan metode histogram equalization, dan adaptive histogram equalization. Nilai MSE yang paling rendah adalah pada metode contrast stretching yaitu 0,00346. Sedangkan nilai MSE yang paling besar dihasilkan oleh metode histogram equalization yaitu 0,00735. Kualitas citra dengan metode contrast stretching menghasilkan nilai PSNR yang paling besar yaitu 22,0677, sedangkan metode yang menghasilkan PSNR kecil adalah histogram equalization yaitu 11,4107.

Kata kunci: medis; peningkatan; *contrast stretching*; *histogram equalization*; *adaptive histogram equalization*.

ABSTRACT

Medical image is a two-dimensional pattern or image inside the human body that is used by health experts to detect and analyze patient's disease. This image will later be analyzed to obtain useful information. But the resulting image sometimes does not match the expected results. This can occur because of a number of possibilities, such as contrast sensitivity, blurredness, visible noise or clarity, spotting, and the details are not clearly illustrated because there are often disturbances in the retrieval process. In the field of image radiology that is often used today is the image of Magnetic resonance imaging (MRI). The advantage of MRI images is the ability to clearly display anatomic details in various pieces (multiplanar) without changing the patient's position. This MRI image will be used by doctors or researchers to analyze whether there is a tumor, cancer, or abnormalities in patients. This study proposes Contrast Stretching method, Histogram Equalization and Adaptive Histogram Equalization to improve the quality of medical images. The limitation of the problem of this research is that MRI medical images which are used as research objects are MRI medical images of normal brain or those with lesions (disorders). The results of image quality and quantitative analysis show that the contrast stretching method produces MRI image quality results far better than the method of histogram equalization, and adaptive histogram equalization. The lowest MSE value is in the contrast stretching method that is 0.00346. While the largest MSE value generated by the method of histogram equalization is 0.00735. Image quality using contrast stretching method produces the highest PSNR value, 22.0677, while the method that produces small PSNR is histogram equalization, which is 11.4107.

Keywords: medical; enhancement; *contrast stretching*; *histogram equalization*; *adaptive histogram equalization*.

1. PENDAHULUAN

Meningkatnya perkembangan ilmu pengetahuan menghasilkan perkembangan teknologi yang berkembang pesat di segala bidang. Perkembangan teknologi kamera dapat menghasilkan kualitas citra yang lebih bagus. Kualitas citra yang dihasilkan akan menentukan seberapa akurat citra itu jika dianalisa. Semua bidang memerlukan citra yang dapat digunakan sebagai penelitian sehingga memungkinkan peneliti memperoleh informasi yang diperlukan [1].

Namun citra yang dihasilkan terkadang tidak sesuai dengan hasil yang diharapkan. Hal ini dapat terjadi karena beberapa kemungkinan, misalnya sensitif terhadap kontras, mengalami keaburan, memiliki *noise* atau kejernihan tampak, memiliki bercak, dan bagian-bagian detailnya tidak tergambar jelas karena sering terdapat gangguan pada proses pengambilannya [2]. Sebelum citra dianalisa, citra terlebih dahulu diproses (*image processing*) agar dapat menghasilkan kualitas yang lebih bagus.

Citra medis merupakan salah satu citra yang paling sering digunakan sebagai obyek penelitian. Citra medis adalah suatu pola atau gambar dua dimensi bagian dalam tubuh manusia yang digunakan oleh ahli kesehatan untuk mendeteksi dan menganalisa penyakit pasien. Beberapa metode dapat digunakan untuk memperoleh citra medis diantaranya: *Magnetic resonance Imaging* (MRI), *X-Ray*, *Ultrasonography* (USG), *Endoscopy*, *Computed Tomography* (CT-Scan) dan *Nuclear Medicine*.

Citra *Magnetic resonance Imaging* (MRI) merupakan citra yang paling sering digunakan pada bidang radiologi [3]. Citra MRI dapat menampilkan detail anatomi obyek secara jelas dalam berbagai potongan (multiplanar) tanpa mengubah posisi pasien. Beberapa permasalahan yang sering terjadi pada citra medis yaitu hasil *scanning* yang mengalami penurunan kualitas yang disebabkan oleh faktor derau. Kualitas citra medis juga disebabkan oleh *noise* acak dengan distribusi rician, ketidakseragaman intensitas sehingga menyebabkan *artifact*, dan efek volume parsial. Dengan permasalahan ini sulit bagi dokter ataupun peneliti untuk melakukan analisa diagnosa kelainan pada pasien. Oleh karena itu maka diperlukan peningkatan kualitas citra medis MRI yang bertujuan menghasilkan citra dengan kualitas yang jauh lebih baik dari citra aslinya.

Penelitian ini membandingkan 3 metode peningkatan kualitas citra yaitu metode *Contrast Stretching*, *Histogram Equalization* dan *Adaptive Histogram Equalization*. Citra medis yang digunakan pada penelitian ini sebagai adalah citra medis MRI Otak baik kondisi normal maupun kondisi yang mengalami lesi (gangguan). Kualitas citra hasil peningkatan dievaluasi berdasarkan parameter MSE, PSNR, dan Sebaran Histogram dari citra. Semua proses penelitian ini menggunakan *Software MATLAB*.

2. KAJIAN PUSTAKA DAN DASAR TEORI

2.1 Kajian Pustaka

Penelitian mengenai peningkatan kualitas citra medis sudah banyak dilakukan diantaranya Rika Rosnelly dan Linda Wahyuni [4]. Peneliti mengemukakan tentang metode perbaikan citra yang digunakan adalah *histogram equalization* dan *contrast stretching*. Data citra parasit malaria berjumlah 60 data citra yang terdiri dari malaria falciparum, vivax, malariae beserta stadium yaitu cincin, trophozoit, skizon dan gametosit. Uji kuantitatif kinerja menggunakan *Mean Square Error* (MSE) dan *Peak Signal to Noise Ratio* (PSNR). Hasilnya adalah *contrast stretching* memberikan kualitas citra yang lebih baik terhadap citra parasit malaria.

Penelitian berikutnya dilakukan oleh Budi Hartono dan Veronica Lusiana [5]. Peneliti mengemukakan tentang analisa kinerja dua buah teknik yaitu ekualisasi histogram adaptif (*Adaptive Histogram Equalization*, AHE) dan perenggangan kontras (*Contrast Stretching*, SC). Kedua teknik ini dapat meningkatkan kualitas atau memperjelas objek citra. Citra uji dalam format JPEG dengan ukuran bervariasi sebanyak 12 buah memiliki tampilan yang berbeda-beda.

Penelitian berikutnya dilakukan oleh Wurood A. Jbara dan Rafah A. Jaafar [6]. Peneliti mengemukakan tentang *Histogram Equalization* (HE) and *Adaptive Histogram Equalization* (AHE) diterapkan untuk memperbaiki kontras citra medis MRI. Hasil percobaan telah mencapai efisiensi yang baik untuk memperbaiki kontras citra medis MRI dengan kualitas sangat tinggi. Berbagai ukuran kualitas seperti MSE, PSNR dan SNR telah diperhitungkan untuk mengevaluasi kualitas citra medis MRI yang disempurnakan.

2.2 Dasar Teori


2.2.1 Citra Digital

Sebuah citra adalah kumpulan piksel-piksel yang disusun dalam larik dua dimensi [7]. Indeks baris dan kolom (x,y) dari sebuah piksel dinyatakan dalam bilangan bulat. Piksel (0,0) terletak pada sudut kiri

atas pada citra, indeks x bergerak ke kanan dan indeks y bergerak ke bawah. Konversi ini dipakai merujuk pada cara penulisan larik yang digunakan dalam pemrograman komputer

2.2.2 Citra Medis Magnetic Resonance Imaging (MRI)

MRI adalah suatu alat diagnostik radiologi yang menghasilkan rekaman gambar potongan penampang organ manusia dengan menggunakan medan magnet [3]. Citra MRI dapat membuat potongan koronal, sagital, aksial tanpa banyak memanipulasi posisi tubuh pasien. Kualitas gambar MRI dapat memberikan gambaran detail tubuh manusia dengan perbedaan yang kontras, sehingga anatomi dan patologi jaringan tubuh dapat dievaluasi secara teliti. Gambar 1 menunjukkan alat MRI dan citra MRI.



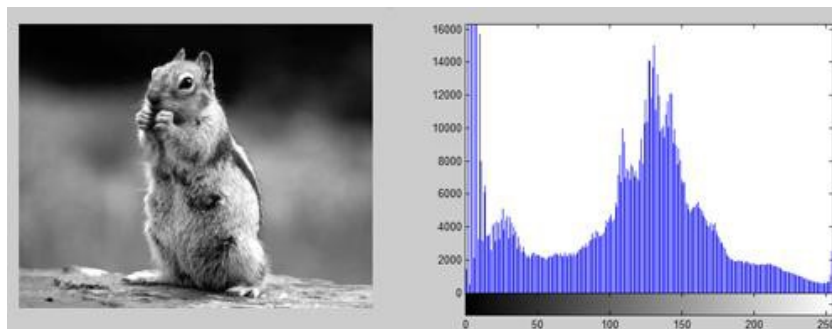
Gambar 1. Alat MRI dan Citra MRI

2.2.3 Peningkatan Kualitas Citra (Image Enhancement)

Peningkatan kualitas citra (*Image Enhancement*) adalah suatu proses untuk mengubah sebuah citra menjadi citra baru sesuai dengan kebutuhan melalui berbagai cara [7].

a. Contrast Stretching

Kontras (*Contrast*) adalah tingkat penyebaran pixel-pixel kedalam intensitas warna [7] [8]. Gambar 2 menunjukkan citra digital masih dalam kondisi normal (belum mengalami peningkatan kualitas).




Gambar 2. Citra Kontras Normal, Mempunyai Kurva Histogram Tidak Lebar dan Tidak Sempit

Contrast Stretching adalah teknik untuk mendapatkan citra baru $f_0(x,y)$ dengan kontras yang lebih baik dari pada kontras citra asalnya $f_i(x,y)$ [9]. Ide dari proses *Contrast Stretching* adalah untuk meningkatkan range dinamis dari *level grayscale* pada gambar saat pemrosesan berlangsung. Disini diasumsikan bahwa citra memiliki *range gray level* dari 0 sampai 255.

$$\text{Komponen RGB untuk grayscale : gray} = (0.3*r) + (0.5*g) + (0.2*b) \quad (1)$$

Gambar 3 menunjukkan proses tranformasi pada metode *Contrast Stretching*.



Gambar 3. Transformasi Contrast Stretching

Jika $A_1 = A_2$ dan $B_1 = B_2$ maka transformasi akan berbentuk garis lurus menandakan tidak ada perubahan *gray level* pada citra yang dihasilkan. Secara umum diasumsikan $A_1 \leq A_2$ dan $B_1 \leq B_2$ sehingga fungsi akan menghasilkan nilai tunggal dan nilainya akan selalu naik. Untuk menghitung nilai hasil transformasi, dapat menggunakan fungsi berikut:

Untuk $0 \leq f_i(x,y) < A_1$, maka

$$f_0(x,y) = f_i(x,y) \frac{B_1}{A_1} \quad (2)$$

Untuk $A_1 \leq f_i(x,y) < A_2$, maka

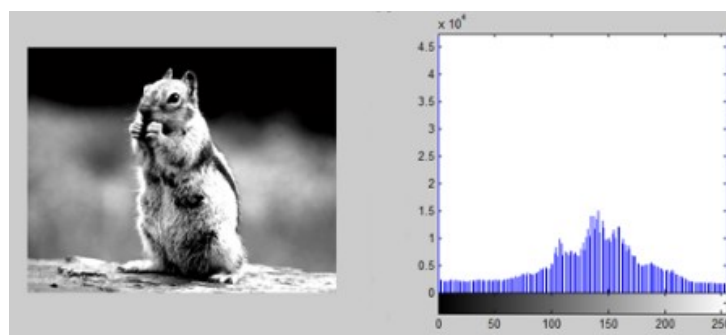
$$f_0(x,y) = B_1 + (f_i(x,y) - A_1) \frac{B_2 - B_1}{A_2 - A_1} \quad (3)$$

Untuk $A_2 \leq f_i(x,y) \leq 255$, maka

$$f_0(x,y) = B_2 + (f_i(x,y) - A_2) \frac{255 - B_2}{255 - A_2} \quad (4)$$

b. Histogram Equalization

Histogram adalah grafik yang menunjukkan frekuensi kemunculan setiap nilai gradasi warna [7] [8]. Pada grafik histogram pada sumbu x menunjukkan tingkat warna sedangkan pada sumbu y menunjukkan frekuensi kemunculan. Gambar 4 menunjukkan citra digital dan sebaran histogram citra asli.



Gambar 4. Citra Asli dan Sebaran Histogram

Teknik yang sering digunakan untuk memproses histogram citra adalah teknik **Histogram Equalization**. Pada teknik *Histogram Equalization* nilai-nilai intensitas didalam citra diubah sehingga penyebarannya seragam (*uniform*) [6] [11]. Perataan histogram diperoleh dengan cara mengubah derajat keabuan suatu pixel (r) dengan derajat keabuan yang baru (s) dengan fungsi transformasi T , yang dalam hal ini $s = T(r)$. Ini berarti r dapat diperoleh kembali dari s dengan transformasi invers $r = T^{-1}(s)$ dimana, $0 \leq s \leq 1$. Tujuan utama dari perataan histogram adalah untuk memperoleh penyebaran histogram yang merata sehingga derajat keabuan memiliki jumlah

pixel yang relatif sama. Karena histogram menyatakan peluang pixel dengan derajat keabuan tertentu maka rumus menghitung perataan hitogram sebagai berikut :

$$P_r(r_k) = \frac{n_k}{n} \text{ dalam hal ini } r_k = \frac{k}{L-1}, 0 \leq k \leq L-1 \quad (5)$$

Artinya derajat keabuan (k) dinormalkan terhadap derajat keabuan terbesar (L-1). Nilai $r_k = 0$ menyatakan hitam, dan $r_k = 1$ menyatakan putih dalam skala keabuan yang didefinisikan.

c. Adaptive Histogram Equalization

Adaptive Histogram Equalization (AHE) adalah teknik pengolahan citra yang digunakan untuk memperbaiki kontras pada citra [8]. Ini berbeda dari pemerataan histogram biasa dengan metode adaptif yang menghitung beberapa histogram, masing-masing sesuai dengan bagian citra yang berbeda, dan menggunakannya untuk mendistribusikan nilai ringan dari citra. Oleh karena itu, cocok untuk memperbaiki kontras lokal dan meningkatkan definisi tepi di setiap wilayah citra. *Adaptive Histogram Equalization* sering juga disebut **Local Histogram Processing**.

2.2.4 Parameter pengukuran

Peningkatan kualitas citra dapat diukur secara kuantitatif menggunakan

- MSE (Mean Square Error)**, yaitu sigma dari jumlah error antara citra hasil peningkatan kualitas dan citra asli. MSE dapat dihitung menggunakan persamaan berikut [7] [8] :

$$MSE = \frac{1}{M \times N} \sum_{i=1}^M \sum_{j=1}^N ((f_a(i,j) - f_b(i,j))^2 \quad (6)$$

M dan N adalah ukuran panjang dan lebar citra.

$f_a(i,j)$ = intensitas citra di titik (i,j) citra asli
 $f_b(i,j)$ = intensitas citra di titik (i,j)
 setelah kualitas ditingkatkan

Semakin kecil nilai MSE, semakin bagus hasil peningkatan kualitas citra. Artinya, kualitas citra setelah mengalami peningkatan kualitas hampir sama dengan kualitas citra aslinya.

- PSNR (Peak Signal to Noise Ratio)**. PSNR dapat dihitung menggunakan persamaan berikut [7] [8]:

$$PSNR = 20 \log_{10} \frac{255}{MSE} \quad (7)$$


Semakin besar nilai PSNR maka citra hasil peningkatan kualitas semakin mendekati citra aslinya. Sebaliknya, semakin kecil nilai PSNR semakin jelek kualitas citra tersebut.

3. METODOLOGI PENELITIAN


Citra yang digunakan adalah Citra MRI Otak (Brain MRI) sejumlah 10 citra baik citra warna (*color image*) maupun citra *grayscale* (*grayscale image*).

Perangkat yang digunakan ada 2 yaitu : perangkat keras (*hardware*) berupa Laptop dan perangkat lunak (*software*) berupa Matlab R2013A.


Penelitian ini berfokus pada peningkatan kualitas citra MRI sebelum dilakukan proses pengolahan citra (*image processing*) berikutnya. Citra MRI yang akan diuji coba adalah citra MRI Otak baik kondisi normal ataupun kondisi terdapat gangguan (lesi). Penelitian ini mengusulkan 3 metode yang digunakan untuk meningkatkan kualitas citra MRI yaitu metode *Contrast Stretching*, *Histogram Equalization*, dan *Adaptive Histogram Equalization*. Gambar 5,6,7 menampilkan perancangan penelitian untuk masing-masing metode yang diusulkan.



Gambar 5. Proses *Contrast Stretching*




Gambar 6. Proses *Histogram Equalization*



Gambar 7. Proses *Adaptive Histogram Equalization*

Output (citra hasil peningkatan) dari ketiga metode tersebut kemudian dibandingkan menggunakan parameter *MSE (Mean Square Error)* dan *PSNR (Peak Signal to Noise Ratio)*. Gambar 8 menampilkan cara menghitung MSE dan PSNR menggunakan *Software MATLAB*.

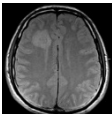
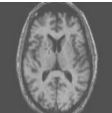
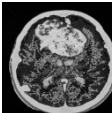
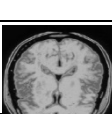


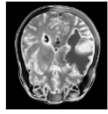
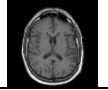
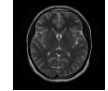
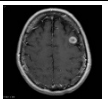
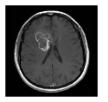
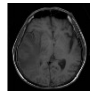
Gambar 8. Blok Diagram Menghitung PSNR

4. HASIL DAN PEMBAHASAN

Tabel 1 menunjukkan hasil data hasil penelitian menggunakan 3 metode. Tabel 2 menunjukkan nilai rata-rata MSE dan PSNR dari ketiga metode yang diusulkan.

Tabel 1. Data hasil penelitian


No	Citra Input	Citra Hasil Peningkatan					
		<i>Contrast Stretching</i>		<i>Histogram Equalization</i>		<i>Adaptive Histogram Equalization</i>	
		MSE	PSNR	MSE	PSNR	MSE	PSNR
1		0,00487	25,3995	0,00742	11,6724	0,00568	19,2761
2		0,00665	17,8974	0,00893	18,6193	0,00891	18,5975
3		0,00431	19,7448	0,00621	11,4961	0,00502	17,6290
4		0,00177	18,7034	0,00537	14,9327	0,00251	15,8848

No	Citra Input	Citra Hasil Peningkatan					
		<i>Contrast Stretching</i>		<i>Histogram Equalization</i>		<i>Adaptive Histogram Equalization</i>	
		MSE	PSNR	MSE	PSNR	MSE	PSNR
5		0,00154	22,6338	0,00868	13,8442	0,00262	18,7750
6		0,00167	25,8964	0,00793	9,1374	0,00316	17,4667
7		0,00178	22,0369	0,00522	6,9495	0,00213	14,5290
8		0,00361	22,5582	0,00779	9,2112	0,005314	16,9421
9		0,00402	22,0833	0,00869	8,7373	0,006023	15,0697
10		0,00275	23,7233	0,00728	9,5070	0,00537	16,7368


Tabel 2. Nilai rata-rata MSE dan PSNR

<i>Contrast Stretching</i>		<i>Histogram Equalization</i>		<i>Adaptive Histogram Equalization</i>	
MSE	PSNR	MSE	PSNR	MSE	PSNR
0,00346	22,0677	0,007352	11,41071	0,0046737	17,09067

4.1 Pembahasan Hasil Penelitian



Gambar 6. Perbandingan Nilai MSE dari Ketiga Metode



Gambar 7. Perbandingan Nilai PSNR dari Ketiga Metode

Pada tabel 3 menunjukkan bahwa metode *contrast stretching*, *histogram equalization*, dan *adaptive histogram equalization* yang dirancang mampu melakukan proses peningkatan kualitas pada citra MRI (Otak). Secara visual ketiga metode yang diusulkan dapat melakukan proses peningkatan kualitas baik pada citra MRI yang kondisi normal maupun citra MRI yang mengalami lesi.

Pada tabel 4 menunjukkan rata-rata hasil perhitungan analisa uji performansi peningkatan kualitas citra MRI dengan beberapa metode. Dari hasil kualitas citra dan analisa kuantitatif menunjukkan bahwa metode *contrast stretching* menghasilkan hasil kualitas citra MRI jauh lebih baik dibandingkan dengan metode *histogram equalization*, dan *adaptive histogram equalization*. Ini dapat dilihat dari nilai :

- Nilai **MSE (Mean Square Error)**. Parameter dari MSE adalah semakin kecil nilai MSE (mendekati 0) menunjukkan bahwa kualitas citra MRI semakin bagus. Pada gambar 11 menunjukkan grafik perbandingan nilai MSE dari ketiga metode yang digunakan. Nilai MSE yang paling rendah adalah pada metode *contrast stretching* yaitu 0,00346 . Sedangkan nilai MSE yang paling besar dihasilkan oleh metode *histogram equalization*. Ini menunjukkan bahwa kualitas citra dengan menggunakan metode *contrast stretching* (CS) menghasilkan kualitas hasil yang lebih bagus dibandingkan metode *histogram* (HE) *equalization*, dan *adaptive histogram equalization* (AHE).
- Nilai **PSNR (Peak Signal to Noise Ratio)** Parameter dari PSNR adalah semakin besar nilai PSNR menunjukkan bahwa kualitas citra MRI semakin bagus atau semakin mendekati citra aslinya. Sebaliknya, semakin kecil nilai PSNR semakin jelek kualitas citra tersebut. Pada gambar 12 menunjukkan grafik perbandingan nilai PSNR. Kualitas citra dengan metode *contrast stretching* menghasilkan nilai PSNR yang paling besar yaitu 22,0677. Ini menandakan bahwa kualitas citra dari metode *contrast stretching* (CS) jauh lebih baik dibandingkan metode *histogram equalization* (HE), dan *adaptive histogram equalization* (AHE).

5. KESIMPULAN

Berdasarkan hasil penelitian dan pembahasan maka dapat disimpulkan bahwa program yang dirancang untuk peningkatan citra MRI menggunakan metode *contrast stretching*, *histogram equalization*, dan *adaptive histogram equalization* dapat berjalan dengan baik dan sesuai dengan yang diharapkan.

Secara visual ketiga metode yang diusulkan dapat melakukan proses peningkatan kualitas baik pada citra MRI yang kondisi normal maupun citra MRI yang mengalami lesi. Citra asli maupun citra hasil peningkatan tidak terdapat perbedaan yang sangat signifikan.

Dari hasil kualitas citra dan analisa kuantitatif menunjukkan bahwa metode *contrast stretching* menghasilkan hasil kualitas citra MRI jauh lebih baik dibandingkan dengan metode *histogram equalization*, dan *adaptive histogram equalization*. Nilai MSE yang paling rendah adalah pada metode *contrast stretching* yaitu 0,00346. Sedangkan nilai MSE yang paling besar dihasilkan oleh metode *histogram equalization*. Kualitas citra dengan metode *contrast stretching* menghasilkan nilai PSNR yang paling besar yaitu 22,0677. Ini menandakan bahwa kualitas citra dari metode *contrast stretching* jauh lebih baik dibandingkan metode *histogram equalization*, dan *adaptive histogram equalization*.

UCAPAN TERIMA KASIH

Penulis mengucapkan terima kasih kepada pihak-pihak yang telah memberi dukungan baik material maupun non material terhadap penelitian ini.

DAFTAR PUSTAKA

- [1] Rohman, M., & Anisah, I. (2013). Retrieved from http://eprints.upnjatim.ac.id/4759/1/071-078_Miftahur_Rohman_2_-_ITS.pdf
- [2] Afriliana Kusumadewi, Sugeng Santoso, "Evaluasi Ciri Citra Medis Menggunakan Metode Peningkatan Kualitas Citra Histogram Equalization Dan Karakteristik Statistik," *Informatika Vol. 11 No. 1*, pp. 1-13, 2015.
- [3] S. A. Riantini, <http://repodig.untan.ac.id/senayan/index.php?p=fstream-pdf&fid=94&bid=94>, 2011.
- [4] Rika Rosnelly, Linda Wahyuni, "Metode Perbaikan Citra pada Citra Parasit Malaria Menggunakan Histogram Equalization dan Constrast Stretching," in *Seminar Nasional Multi Disiplin Ilmu*, Tangerang, 2017.
- [5] Budi Hartono, Veronica Lusiana, "Analisa Teknik Adaptive Histogram Equalization Dan Contrast Stretching Untuk Perbaikan Kualitas Citra," *Jurnal Teknologi Informasi Dinamik Volume 19 No. 1*, pp. 1-10, 2014.
- [6] Wurood A. Jbara, Rafah A. Jaafar, "MRI Medical Images Enhancement based on Histogram Equalization and Adaptive Histogram Equalization," *International Journal of Computer Trends and Technology Volume 50 Number 2*, pp. 91-93, 2017.
- [7] T. Sutoyo, Edy Mulyanto, Vincent Suhartono, Oky Dwi Nurhayati, Wijanarto, *Teori Pengolahan Citra Digital*, Semarang : Andi Offset Yogyakarta, 2009.
- [8] Gonzalez, Woods, *Digital Image Processing 2nd Edition*, Prentice Hall, 2002.
- [9] Suhardi, Wahyu Setia Budi, Choirul Anam, "UPAYA PENINGKATAN KUALITAS CITRA MRI DENGAN PEMBERIAN MEDIA KONTRAS," *Berkala Fisika Vol. 16 No. 1*, pp. 9-14, 2013.
- [10] Al-Tamimi, M.S.H., Sulong G., "Tumor Brain Detection Through MR Images : A Review Of Literature," *J. Theor. Appl. Inf. Technol.* 62., 2014.
- [11] Hardeep kaur, Jyoti Rani, "MRI brain image enhancement using Histogram equalization Techniques," *IEEE*, pp. 770-773, 2016.
- [12] H. R. Fajrin, "Perbandingan Metode Untuk Perbaikan Kualitas Citra Mammogram," *Jurnal Simetris Vol.7 No.2*, pp. 657-664, 2016.
- [13] D. Nirmala, "Medical image contrast enhancement techniques," *Journal of Chemical and Pharmaceutical Research*, pp. 1-8, 2015.
- [14] N Senthilkumaran, J Thimmiraja, "A Study on Histogram Equalization for MRI Brain Image Enhancement," *Association of Computer Electronics and Electrical Engineers*, pp. 317-325, 2014.
- [15] N. Wakhidah, "Perbaikan Kualitas Citra Menggunakan Metode Contrast Stretching (Improvement of image quality using a method Contrast Stretching)," *JURNAL TRANSFORMATIKA Volume 8 No.2*, pp. 78-83, 2011.
- [16] Senthilkumaran N, Thimmiraja J, "Histogram Equalization for Image Enhancement Using MRI brain images," *IEEE*, pp. 80-83, 2014.
- [17] G.Amar Tej, Prashanth.K.Shah, "Efficient quality analysis and enhancement of MRI image using Filters and Wavelets," *International Journal of Advanced Research in Computer and Communication Engineering Vol. 4 Issue 6*, pp. 230-236, 2015.
- [18] E. Ben George, M.Karnan, "MRI Brain Image Enhancement Using Filtering Techniques," *International Journal of Computer Science & Engineering Technology Vol. 3 No. 9*, pp. 399-403, 2012.
- [19] Mohamed Y. Adam, Mozamel M. Saeed, Al Samani A. Ahmed, "Medical Image Enhancement Application Using Histogram Equalization in Computational Libraries," *International Journal of Computer Science and Telecommunications Volume 6 Issue 1*, pp. 7-12, 2015.
- [20] Sumaya, Zena Vatsa, "MRI Image Enhancement," *International Journal of Science and Research (IJSR) Volume 4 Issue 5*, pp. 1757-1758, 2015.
- [21] UdayKumbhar, Vishal Patil, Shekhar Rudrakshi, "Enhancement Of Medical Images Using Image Processing In Matlab," *International Journal of Engineering Research & Technology (IJERT) Vol. 2*

Issue 4, pp. 2359-2364, 2013.

- [22] I Wayan Angga Wijaya Kusuma, Rossy Lydia Ellyana, "Penerapan Citra Terkompresi Pada Segementasi Citra Menggunakan Algoritme K-Means," *Jurnal Terapan Teknologi Informasi*, pp. 65-74, 2018.

Pengaruh Contrast Limited Adaptive Histogram Equalization Dalam Klasifikasi CT-Scan Tumor Ginjal Menggunakan Deep Learning

Nanda Jannata¹, Febi Yanto², Lestari Handayani³, Eka Pandu Cynthia Kurnia⁴

^{1,2,3,4} Program Studi Teknik Informatika

Universitas Islam Negeri Sultan Syarif Kasim, Pekanbaru, Riau, Indonesia

E-mail: 11950111721@students.uin-suska.ac.id¹, febiyanto@uin-suska.ac.id^{*2},

Lestari.handayani@uin-suska.ac.id³, eka.pandu.cynthia@uin-suska.ac.id⁴

Abstract – The human excretory system, comprising the kidneys, ureters, and bladder, plays a crucial role in maintaining overall body health by filtering blood and eliminating waste products, including water and toxins. However, kidneys are susceptible to various diseases, such as kidney tumors, which present a significant global health challenge, with over 430,000 new cases reported in 2020. This research focuses on using CT-scan imaging techniques to analyze and assess kidney tumors. The study employs the Image Enhancement Contrast Limited Adaptive Histogram Equalization (CLAHE) method to enhance the quality of Kidney Tumor CT-Scan images for deep learning classification using the MobileNetV2 Architecture. The dataset, consisting of 4,560 images, is divided into training, validation, and testing sets in an 80:20 ratio. Applying CLAHE with a clip limit of 20 and an 8x8 tile grid significantly improves evaluation metrics compared to non-CLAHE datasets, achieving an impressive f1-score of 99.56% and accuracy of 99.56%. This improvement is achieved using the Adam optimizer with a learning rate of 0.01. These findings underscore the efficacy of CLAHE in enhancing the model's performance in kidney tumor classification. They are particularly valuable for radiologists as they enhance diagnostic accuracy and efficiency, potentially reducing diagnostic errors and improving patient outcomes.

Keywords – CLAHE, Classification, CT-Scan, MobileNetV2, Tumor, Kidney.

Intisari - Sistem ekskresi manusia, yang terdiri dari ginjal, ureter, dan kandung kemih, memainkan peran penting dalam menjaga kesehatan tubuh. Ginjal, organ vital dalam sistem ekskresi, bertanggung jawab untuk menyaring darah dan membuang limbah, termasuk air dan racun, dari tubuh. Namun, ginjal dapat terserang berbagai penyakit, salah satunya adalah tumor ginjal. Tumor ginjal menjadi masalah kesehatan global yang signifikan, dengan lebih dari 430.000 kasus baru dilaporkan pada tahun 2020. Penelitian ini menggunakan metode pencitraan CT-scan untuk analisis dan penilaian tumor ginjal. Teknik *Image Enhancement Contrast Limited Adaptive Histogram Equalization* (CLAHE) diterapkan untuk meningkatkan kualitas citra CT-Scan Tumor Ginjal dalam klasifikasi *deep learning* menggunakan Arsitektur *MobileNetV2*. Dataset CT-Scan Tumor Ginjal yang terdiri dari 4.560 gambar dibagi menjadi data pelatihan, validasi, dan pengujian dengan rasio 80:20. Penggunaan CLAHE dengan clip limit 20 dan tile grid 8x8 menghasilkan hasil evaluasi yang lebih tinggi dibandingkan dataset *non-clahe*, yaitu f1-score 99,56% dan accuracy 99,56%. Hal ini dicapai dengan optimizer Adam dan learning rate 0,01. Temuan ini menunjukkan bahwa penerapan teknik CLAHE dapat meningkatkan kinerja model dalam mengklasifikasikan tumor ginjal. Hasil ini sangat penting bagi ahli radiologi karena memungkinkan mereka untuk mendiagnosis tumor ginjal dengan lebih akurat dan efisien, meningkatkan hasil diagnosa pasien dan mengurangi risiko kesalahan.

Kata Kunci - CLAHE, Klasifikasi, CT-Scan, MobileNetV2, Tumor, Ginjal.

I. PENDAHULUAN

Ginjal berfungsi menyaring darah, menjaga keseimbangan air dan garam, membuang limbah, mengatur tekanan darah, membantu produksi sel darah merah, dan mendukung kesehatan tulang. Ginjal yang rusak dapat menyebabkan berbagai penyakit dan berdampak pada organ lain[1]. Penyakit ginjal telah menjadi masalah utama masyarakat diseluruh dunia[2]. Menurut *World Cancer Reaserch Fund Internasional*, Ada lebih dari 430.000 kasus baru kanker ginjal pada tahun 2022[3].

CT-scan, yang merupakan singkatan dari *tomografi computer*, dipandang sebagai salah satu metode pencitraan terbaik dan telah menjadi standar untuk analisis serta penilaian tumor di dalam ginjal[4]. CT-scan memberikan gambaran yang lebih detail tentang struktur *vaskular*, memungkinkan untuk membedakan berbagai elemen desain interior seperti dimensi, kepadatan, dan struktur[5] Peningkatan jumlah gambar medis dapat menyulitkan spesialis, yang sering kali mengakibatkan keterlambatan dalam mendeteksi tumor. Hal ini dapat mengakibatkan penundaan dalam pengobatan yang dapat berdampak negatif pada pasien[6]. Oleh karena itu, penggunaan teknologi pencitraan untuk melakukan perbandingan struktur kompleks jaringan ginjal yang sehat dan yang mengalami gangguan menjadi sangat penting[7]. *Convolutional Neural Network* (CNN) adalah jenis jaringan saraf yang secara khusus dirancang untuk menganalisis gambar dan memproses *visi komputer*[8].

CNN telah mencapai pencapaian yang luar biasa dalam memprediksi tumor di berbagai bidang[9]. Namun, untuk mencapai hasil yang optimal, CNN memerlukan dataset yang besar dan berlabel dengan baik, serta variasi kualitas gambar yang baik. *Image enhancement* merupakan salah satu teknik pemrosesan citra yang dapat meningkatkan interpretasi informasi gambar sehingga kualitasnya meningkat. menjadi penting karena dataset citra medis seringkali memiliki resolusi rendah dan tingkat kontras yang tidak seragam[10]. Metode *image enhancement* dapat dilakukan pada dua domain, yaitu *spasial* atau *frekuensi*. Penyetaraan *histogram* merupakan teknik yang dikenal dalam pemrosesan citra di domain spasial karena efektivitasnya yang tinggi dan kemudahan penerapannya, terutama dalam bidang medis[11]. *Histogram Equalization* (HE) adalah teknik yang menghasilkan gambar di mana tingkat intensitasnya tersebar secara merata di seluruh gambar, mencakup seluruh rentang intensitas. Efek dari proses ini adalah gambar dengan dinamika rentang yang lebih besar mengalami peningkatan kontras[12]. Meningkatkan kontras gambar menggunakan HE memiliki kekurangan, terutama saat digunakan pada citra medis CT-Scan dengan intensitas tinggi. Penerapan HE sederhana dapat mengakibatkan beberapa area gambar CT-Scan menjadi terlalu intens, menyebabkan kehilangan detail yang penting. Dalam kasus ini, CLAHE dapat menjadi solusi yang lebih sesuai[13]

Banyak penelitian telah dilakukan dalam pengolahan citra medis, termasuk klasifikasi kanker kulit menggunakan metode *Support Vector Machine* (SVM) dan *K-Nearest Neighbor* (KNN)[14] Namun, pengembangan terbaru dalam *Machine Learning*, yaitu *Deep Learning*, menjanjikan akurasi yang lebih tinggi. Penelitian yang membandingkan SVM, KNN, dan CNN menunjukkan bahwa CNN mencapai akurasi tertinggi, yaitu 0,942[15]. Penelitian CNN untuk menguji kemampuan model dalam memprediksi jenis penyakit ginjal menggunakan dataset yang diperoleh dari platform Kaggle telah dilakukan. Model CNN mampu mengklasifikasikan citra dengan baik antara ginjal normal dan ginjal kista. Namun, terdapat kesulitan dalam membedakan antara citra ginjal batu dan ginjal tumor karena kemiripan visualnya dengan citra ginjal kista. Hasil akhir dari uji coba menunjukkan tingkat akurasi sebesar 75,17% dengan nilai *f1-score* sebesar 68%[16]. CNN digunakan dalam pengolahan citra medis untuk klasifikasi, segmentasi, dan deteksi[17], Algoritma ini telah diterapkan dalam beberapa penelitian klasifikasi citra medis [18][19]. Oleh karena itu, penelitian ini mengadopsi algoritma CNN untuk melakukan klasifikasi tumor ginjal. Pada tahap preprocessing, dilakukan proses resize


dan penggunaan teknik image enhancement dengan CLAHE untuk meningkatkan kontras pada citra CT-Scan.

II. SIGNIFIKANSI STUDI

Berdasarkan penelitian sebelumnya yang dipublikasikan di Connel University pada 8 April 2024 dengan judul *Comparative Analysis of Image Enhancement Techniques for Brain Tumor Segmentation: Contrast, Histogram and Hybrid Approaches*. penelitian ini membandingkan algoritma image enhancement diantaranya HE, CLAHE, HE-CLAHE dan CLAHE-HE, dari penelitian ini. dari penelitian ini didapat kan Algoritma CLAHE mencapai akurasi 98,62 dan Dice 99,30 sedikit lebih rendah dibandingkan Algoritma CLAHE-HE dengan akurasi 98,60 dan Dice 99,29. sedangkan algoritma HE mendapatkan akurasi 98,16 dan Dice 99,07 dan HE-CLAHE 98,57 akurasi dan 99,23 Dice. Baik AHE dan CLAHE sama memiliki performa yang baik, algoritma mana yang lebih tepat untuk digunakan pada penelitian tergantung pada aplikasi dan kebutuhan spesifik[20]

Penelitian lain nya mengenai clahe pada tahun 2019 dengan judul *Comparative study of Histogram Equalization Enhancement Techniques for Medical Images*, penelitian ini membandingkan algoritma image enhancement Adaptive Histogram Equalization (AHE), Histogram Equalization (HE) dan Contrast Limited Adaptive Histogram Equalization (CLAHE). Hasil dari penelitian ini didapatkan Algoritma AHE memiliki nilai Entropi yang baik dan Nilai SNR yang stabil akan tetapi AHE mendapatkan nilai SSIM yang buruk. disisi lain Algoritma CLAHE memiliki nilai SIIM terbaik dengan nilai Entropi dan SNR Sedang[11].

Penelitian ini mengeksplorasi Pengaruh Contrast Limited Adaptive Histogram Equalization dalam klasifikasi CT scan tumor ginjal menggunakan deep learning. Untuk mencapai hasil yang optimal, penelitian ini dibagi menjadi beberapa tahap, seperti yang digambarkan dalam gambar berikut.




Gambar 1. Metodologi Penelitian

Gambar 1. menggambarkan alur kerja yang Tahapannya meliputi Dataset, preprocessing data, pembagian data, implementasi *deep learning*, dan evaluasi. Tahapan awal adalah preprocessing, pada tahap ini dilakukan *resizing* dan *image enhancement*, untuk memastikan konsistensi data dengan input yang dibutuhkan dalam proses deep learning. Setelah itu, data yang telah diproses dari tahap sebelumnya akan dilatih menggunakan *deep learning*, data yang telah dilatih akan dievaluasi menggunakan metode *confusion matrix*.

A. Dataset

Dataset yang digunakan dalam penelitian ini berasal dari artikel yang dipublikasikan di PubMed pada tahun 2022 dengan judul "Vision transformer and explainable transfer learning models for auto detection of kidney cyst, stone and tumor from CT-Radiography". Dataset original terdiri dari 12.466 data dengan 4 kelas: Normal, kista, batu, dan tumor. dataset dikumpulkan dari rumah sakit di dhaka bangladesh, semua gambar diverifikasi oleh dokter dan ahli teknologi medis untuk memastikan kembali kebenaran data. kumpulan data yang digunakan dalam penelitian ini berjumlah 4.560 gambar CT ginjal, total ada dua kelas. 2.280 gambar kelas nomal, dan 2.280 kelas tumor[21].



Gambar 2 (a) Ginjal Normal Gambar 2 (b) Ginjal Tumor

Gambar 2 (a) menampilkan citra medis dari ginjal normal, yang telah diperoleh dari dataset terverifikasi. Dataset ini telah dikonfirmasi keakuratannya oleh dokter dan ahli teknologi medis. Sementara itu, Gambar 2 (b) memperlihatkan citra medis dari tumor ginjal, di mana area tumor telah ditandai dengan jelas untuk memudahkan identifikasi.

B. Preprocessing


Preprocessing terbagi menjadi dua tahap: *resizing* dan *image enhancement*. Data akan di-*resize* dan ditingkatkan kontrasnya menggunakan proses image enhancement dengan metode CLAHE. CLAHE menggunakan nilai ambang batas yang rendah saat mengubah *histogram*. Teknik ini meningkatkan kualitas gambar dengan meningkatkan kontras, sambil menghindari peningkatan *noise* yang berlebihan dan mengurangi efek bayangan tepi[22] Nilai ambang batas ditentukan dengan menggunakan batas *klip*[23].

1. Resize

Data CT-Scan Ginjal akan diubah ukurannya menjadi 224x224 piksel untuk menyesuaikan dengan input yang diharapkan oleh model MobileNetV2. Model MobileNetV2 dirancang untuk menerima input gambar dengan dimensi 224x224 piksel, meskipun model ini juga dapat menerima input dengan dimensi yang lebih kecil, mulai dari 96x96 piksel[24].

2. Contrast Limited Adaptive Histogram Equalization (CLAHE)

CLAHE diterapkan untuk meningkatkan kontras pada gambar sebelum Deep Learning. Teknik ini membatasi amplifikasi histogram dengan nilai batas (*clip limit*) untuk mengurangi keabuan gambar. Histogram asli tiap blok gambar dipotong dari atas jika melebihi *clip limit*. Bagian histogram yang dipotong ini kemudian didistribusikan secara merata ke seluruh rentang piksel dalam histogram.



Gambar 3. Proses pemotongan dan redistribusi histogram (Gabriel Fillipe CC, EURASIP Journal on Image and Video Processing 2019)

Gambar 3, Histogram CLAHE adalah representasi grafis distribusi nilai intensitas piksel dalam gambar yang telah diproses dengan teknik CLAHE. Sumbu X (Nilai Intensitas Piksel) Menunjukkan nilai intensitas piksel dalam gambar, mulai dari 0 (hitam) hingga 255 (putih). Sumbu Y (Jumlah Piksel) Menunjukkan jumlah piksel dalam gambar yang memiliki nilai intensitas piksel yang sesuai dengan nilai pada sumbu X. CLAHE di OpenCV memanfaatkan dua parameter utama: *tile grid size* dan *clip limit*. Pertama, *tile grid size* dan *clip limit* ditentukan. Kemudian, histogram dibuat untuk setiap *tile* (kotak kecil) pada gambar. Histogram

tile dipotong berdasarkan clip limit, nilai di atas clip limit didistribusikan kembali ke seluruh histogram[25]. histogram yang telah diubah diterapkan pada gambar untuk meningkatkan kontras.

C. Deep Learning

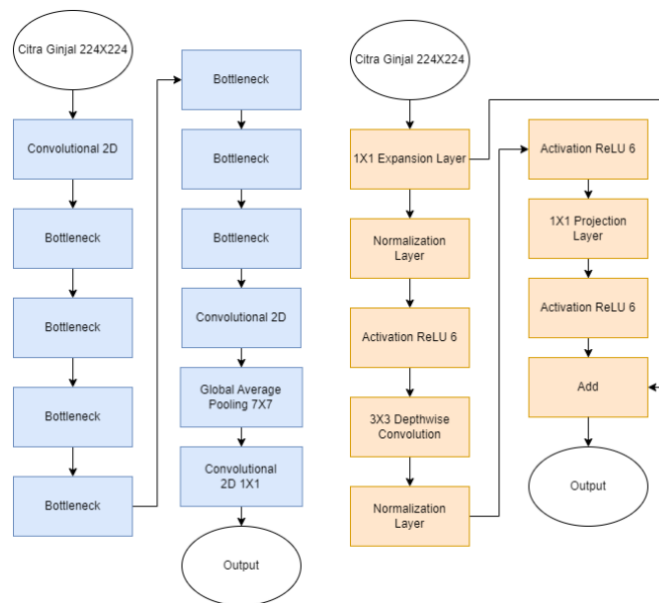
Setelah dataset dilakukan CLAHE dan *resize*, selanjutnya data dibagi menjadi data latih, data validasi, dan data uji. Proses pembagian dataset dibagi dengan rasio 80% dari total dataset digunakan untuk pelatihan, 10% untuk validasi, dan 10% untuk pengujian. Sehingga masing-masing kelas terdiri dari 1824 data latih, 228 data validasi, 228 data uji.

TABEL I
PEMBAGIAN DATASET

Kelas	Dataset Non-CLAHE			Dataset CLAHE		
	Pelatihan (80%)	Validasi (10%)	Pengujian (10%)	Pelatihan (80%)	Validasi (10%)	Pengujian (10%)
Normal	1824	228	228	1824	228	228
Tumor	1824	228	228	1824	228	228

1. MobileNetV2

MobileNetV2 merupakan CNN yang telah digunakan untuk masalah klasifikasi[26], *MobileNetV2* memiliki struktur yang terdiri dari beberapa lapisan *konvolusi* standar dengan ukuran *kernel* 3×3 piksel, yang menghasilkan 32 *channel output*. Kemudian, terdapat beberapa lapisan *bottleneck residual* yang menerapkan proses *depthwise separable convolution* dengan ukuran *kernel* 3×3 piksel. Pada bagian akhir dari model dasar ini, terdapat lapisan konvolusi pointwise yang menghasilkan output dengan dimensi $7 \times 7 \times 1024$ piksel, yang ditunjukkan pada gambar 4.



Gambar 4. Arsitektur *MobileNetV2*

2. Evaluasi

Dalam evaluasi efektivitas jaringan saraf, penggunaan metrik seperti akurasi, presisi, recall, F1 score, dan confusion matrix adalah krusial. Semua metrik ini, beserta rumus matematisnya, diuraikan secara rinci dalam bagian ini untuk memberikan pemahaman yang mendalam tentang performa model[27]. Model akan diuji menggunakan data uji yang telah

dipisahkan sebelumnya. Data uji terbagi menjadi dua kategori, tumor dan normal. Terdapat total 228 data uji untuk kategori tumor dan 228 data uji untuk kategori normal.

1. Accuracy

Accuracy mengukur persentase *instance* yang diklasifikasikan secara benar dari total jumlah *instance* dalam dataset.

$$\text{Akurasi} = \frac{TP+FP}{TP+FP+TP+FN} \quad (1)$$

Dalam klasifikasi multikelas, akurasi memperhitungkan semua kelas dan menghitung persentase *instance* yang diklasifikasikan secara benar di semua kelas

2. Precision

Precision menilai kemampuan model dalam mengidentifikasi dengan benar *instance* yang sesuai dengan kelas tertentu dari semua contoh yang diprediksi oleh model sebagai kelas tersebut.

$$\text{Presisi} = \frac{TP}{TP+FP} \quad (2)$$

3. Recall

Recall, dikenal sebagai sensitivitas atau tingkat positif actual[28], merupakan metrik evaluasi penting dalam klasifikasi multikelas dalam deep learning. *recall* menghitung berapa persen ketepatan model dalam memprediksi kelas positif yang sebenarnya.

$$\text{Recall} = \frac{TP}{TP+FN} \quad (3)$$

4. F1-Score

F1 Skor adalah rata-rata harmonik dari presisi dan recall. Dalam klasifikasi multikelas, skornya dihitung untuk setiap kelas secara terpisah dan kemudian dikumpulkan menjadi satu nilai.

$$F1 - \text{Score} = 2 \times \frac{\text{Precision} \times \text{recall}}{\text{Precision} + \text{recall}} \quad (4)$$

III. HASIL DAN PEMBAHASAN


A. Penerapan Contrast Limited Adaptive Histogram Equalization

Proses ini bertujuan untuk menemukan kombinasi optimal dari nilai *Clip limit* yang akan diterapkan pada model *MobileNetV2* selama proses pelatihan data. Penyesuaian model ini ditujukan untuk mencapai kinerja terbaik dalam hal *f1-score* dan *accuracy* pada data validasi asli.

TABEL II
HASIL PEMILIHAN CLIP LIMIT


No.	Rasio Dataset	Optimizer	Tile Grid	Clip Limit	F1 Score	Accuracy
1	80:20	Adam	8x8	2	99,13	99,12
2	80:20	Adam	8x8	12	97,55	97,59
3	80:20	Adam	8x8	20	99,56	99,56
4	80:20	SGD	8x8	2	93,72	93,42
5	80:20	SGD	8x8	12	89,58	89,04
6	80:20	SGD	8x8	20	92,69	92,32
7	80:20	Adagrad	8x8	2	88,55	88,60
8	80:20	Adagrad	8x8	12	85,45	85,96
9	80:20	Adagrad	8x8	20	88,07	87,94

Tabel II menampilkan hasil dari pemilihan *clip limit* yang akan digunakan pada pelatihan *clahe*. pelatihan model dilakukan pada 3 Nilai *Clip Limit* yaitu 2, 12, dan 20. Penerapan CLAHE dengan clip limit 20 pada citra medis memungkinkan peningkatan kontras yang lebih besar, memfasilitasi pemisahan struktur citra dengan lebih jelas, seperti membedakan antara jaringan normal dan tumor. Ukuran tile grid 8x8 memperhalus penyesuaian kontras, meningkatkan detail dan visibilitas fitur penting. Kombinasi dataset yang seimbang dan penggunaan optimizer Adam telah terbukti efektif dengan Memperoleh hasil pelatihan dengan *accuracy* tertinggi pada eksperimen ke-3 dengan perolehan *f1-score* 99,56% dan *accuracy* 99,56%.




Gambar 5. Perbandingan Citra *Non-Clahe* dan Citra *CLAHE*


Gambar 5 (a) menunjukkan citra medis ginjal normal tanpa penerapan CLAHE, dan histogram untuk citra tersebut dapat dilihat pada Gambar 6 (a). Sementara itu, Gambar 5 (b) menampilkan citra medis ginjal normal setelah penerapan CLAHE dengan clip limit 2, dengan histogramnya ditampilkan pada Gambar 6 (b). Gambar 5 (c) memperlihatkan citra medis ginjal normal dengan penerapan CLAHE clip limit 12, yang histogramnya dapat dilihat pada Gambar 6 (c). Terakhir, Gambar 5 (d) menunjukkan citra medis ginjal normal setelah penerapan CLAHE dengan clip limit 20, dengan histogramnya ditampilkan pada Gambar 6 (d).




Gambar 6 (a) Histogram Citra ginjal Non Clahe



Gambar 6 (b) Histogram Citra ginjal Clahe dengan Clip limit 2



Gambar 6 (a) Histogram Citra ginjal Non Clahe dengan Clip Limit 12



Gambar 6 (a) Histogram Citra ginjal Non Clahe dengan Clip Limit 20


B. Proses Training

Model MobileNetV2 dari TensorFlow akan dilatih untuk mengenali citra dengan baik. Data dibagi menjadi 80% untuk pelatihan, 20% untuk validasi dan uji. Model dioptimalkan dengan 3 optimizer (Adam, SGD, Adagrad) dan 3 learning rate (0.01, 0.001, 0.0001) untuk mencari kombinasi terbaik. Pelatihan berlangsung selama 50 epoch, dan dihentikan jika akurasi validasi tidak meningkat selama 10 epoch berturut-turut (early stopping). Performa model dievaluasi dengan precision, recall, f1-score, dan accuracy, dihitung dari confusion matrix.

TABEL III
HASIL TRAIN DATASET NON-CLAHE

NO	Optimizer	Learning Rate	Training Loss	Training Accuracy	Validation Loss	Validation Accuracy
1	Adam	0,01	0.3200	0.8972	0.0582	0.9868
2	Adam	0,001	0.2209	0.9117	0.1224	0.9868
3	Adam	0,0001	0.6146	0.6993	0.4011	0.8570
4	SGD	0,01	0.3703	0.8366	0.1725	0.9518
5	SGD	0,001	0.4290	0.7950	0.3184	0.9145
6	SGD	0,0001	0.7635	0.6102	0.5112	0.8377
7	Adagrad	0,01	0.3122	0.8662	0.2105	0.9605
8	Adagrad	0,001	0.7650	0.6102	0.5269	0.7763
9	Adagrad	0,0001	1.0915	0.4989	0.7453	0.4605

Tabel III menampilkan pelatihan model menggunakan dataset *non-clahe*. Proses pelatihan dilakukan dengan variasi *hyperparameter* dan *Learning Rate* yang berbeda, dengan iterasi hingga 50 epoch. Eksperimen kedua menunjukkan hasil pelatihan dengan *validation binary accuracy* tertinggi untuk dataset *non-clahe*, dengan *training accuracy* mencapai 91,17% dan *validation accuracy* mencapai 98,68%.



Gambar 7. Grafik Pelatihan Dataset Non-Clahe


Gambar 7 menunjukkan grafik pelatihan untuk dataset *non-clahe* pada percobaan ke-2 menggunakan *optimizer Adam* dengan *learning rate* 0.001. Pada grafik terdapat garis biru yang menunjukkan *binary accuracy* dan garis oranye menunjukkan validasi. Eksperimen ini mendapatkan hasil *training binary accuracy* 0.9117 dan *validation binary accuracy* 0.9868. menunjukkan peningkatan performa dan minimnya overfitting.

TABEL IV
HASIL TRAIN DATASET CLAHE

NO	Optimizer	Learning Rate	Training Loss	Training Accuracy	Validation Loss	Validation Accuracy
1	Adam	0,01	0.0238	0.9929	0.0096	0.9956
2	Adam	0,001	0.0811	0.9838	0.0786	0.9868
3	Adam	0,0001	0.2283	0.9397	0.2097	0.9474
4	SGD	0,01	0.0853	0.9756	0.0691	0.9846
5	SGD	0,001	0.1806	0.9454	0.1656	0.9518
6	SGD	0,0001	0.4352	0.8259	0.3912	0.8991

NO	Optimizer	Learning Rate	Training Loss	Training Accuracy	Validation Loss	Validation Accuracy
7	Adagrad	0,01	0.1154	0.9775	0.1030	0.9868
8	Adagrad	0,001	0.4511	0.8161	0.4380	0.8421
9	Adagrad	0,0001	0.7670	0.4978	0.7188	0.4846

Tabel IV menampilkan pelatihan model menggunakan dataset CLAHE. Proses pelatihan dilakukan dengan *variasi hyperparameter* dan *Learning Rate* yang berbeda, dengan iterasi hingga 50 epoch. Eksperimen pertama menunjukkan hasil pelatihan dengan *training accuracy* untuk dataset CLAHE, dengan *training accuracy* mencapai 99,29% dan *validation accuracy* mencapai 99,56%.



Gambar 8. Grafik Pelatihan Dataset *Clahe*

Gambar 8 menunjukkan grafik pelatihan untuk dataset *clahe* pada percobaan ke-2 menggunakan *optimizer Adam* dengan *learning rate* 0.001. pada grafik terdapat garis biru yang menunjukkan *binary accuracy* dan garis oranye menunjukkan validasi, Eksperimen ini mendapatkan hasil *training binary accuracy* 0.9929 dan *validation binary accuracy* 0.9956. menunjukkan peningkatan performa dan minimnya overfitting.

C. Pengujian Model


Setelah menyelesaikan pelatihan model dengan dataset *non-clahe* dan dataset yang telah ditingkatkan kontrasnya menggunakan CLAHE, langkah berikutnya adalah menguji model menggunakan dataset pengujian. Pengujian ini akan mencakup semua model yang telah dilatih dengan kedua jenis dataset tersebut. Evaluasi kinerja model akan dilakukan dengan menganalisis confusion matrix, memperhatikan nilai akurasi, presisi, recall, dan f1-score, serta hasil prediksi untuk setiap kelas.

TABEL V
HASIL PENGUJIAN MENGGUNAKAN DATASET NON-CLAE DAN DATASET CLAE

No.	Rasio Dataset	Dataset	Optimizer	Learning Rate	Accuracy	Precision	Recall	F1-Score
1	80:20	Non CLahe	Adam	0.01	98.68	99.55	97.81	98.67
2	80:20	Non CLahe	Adam	0.001	53.95	56.16	35.96	43.85
3	80:20	Non CLahe	Adam	0.0001	88.82	88.31	89.47	88.89
4	80:20	Non CLahe	SGD	0.01	96.93	94.21	100.00	97.02
5	80:20	Non CLahe	SGD	0.001	91.89	89.30	95.18	92.14
6	80:20	Non CLahe	SGD	0.0001	92.14	81.57	91.23	86.13
7	80:20	Non CLahe	Adagrad	0.01	97.15	96.14	98.25	97.18
8	80:20	Non CLahe	Adagrad	0.001	80.48	81.17	79.39	80.27
9	80:20	Non CLahe	Adagrad	0.0001	44.30	44.25	43.86	44.05
10	80:20	CLAE	Adam	0.01	99.56	99.13	100.00	99.56


No.	Rasio Dataset	Dataset	Optimizer	Learning Rate	Accuracy	Precision	Recall	F1-Score
11	80:20	CLAHE	Adam	0.001	98.46	97.02	100.00	98.49
12	80:20	CLAHE	Adam	0,0001	95.61	96.43	94.74	95.58
13	80:20	CLAHE	SGD	0,01	99.12	99.56	98.68	99.12
14	80:20	CLAHE	SGD	0,001	98.46	97.02	100.00	98.49
15	80:20	CLAHE	SGD	0,0001	87.61	88.16	91.83	83.77
16	80:20	CLAHE	Adagrad	0,01	99.12	98.70	99.56	99.13
17	80:20	CLAHE	Adagrad	0,001	86.62	85.84	87.72	86.77
18	80:20	CLAHE	Adagrad	0.0001	63.60	62.50	67.98	65.13

Tabel V merupakan hasil pengujian yang dilakukan menggunakan data uji yang belum pernah digunakan sebelumnya. Hasil pengujian pada dataset *non-clahe* mencapai akurasi tertinggi pada percobaan ke-1, sedangkan pada dataset *clahe* mencapai akurasi tertinggi pada percobaan ke-10.



Gambar 9. *Confusion Matrix* Dataset *Non-Clahe*

Gambar 9. Predicted Labels menunjukkan label yang diprediksi oleh model, sementara True Labels menunjukkan label yang sebenarnya. Model ini sangat akurat dalam memprediksi kedua kelas, hanya membuat 2 kesalahan prediksi di mana data Normal diprediksi sebagai Tumor, dan tidak ada kesalahan prediksi untuk data Tumor yang diprediksi sebagai Normal. Hasil pengujian dari percobaan ke-1 dapat dilihat pada Gambar 8 yang menunjukkan hasil *confusion matrix* dengan *accuracy* 98.68%, *precision* 99.55%, *recall* 97.81%, *f1-score* 98.67%.




Gambar 10. *Confusion Matrix* Dataset *Contrast Limited Adaptive Histogram Equalization*

Gambar 10. Predicted Labels menunjukkan label yang diprediksi oleh model, sementara True Labels menunjukkan label yang sebenarnya. Model ini sangat akurat dalam memprediksi kedua kelas, hanya membuat 2 kesalahan prediksi di mana data Normal diprediksi sebagai Tumor, dan tidak ada kesalahan prediksi untuk data Tumor yang diprediksi sebagai Normal, Hasil pengujian dari percobaan ke-10 dapat dilihat pada Gambar 9 yang menunjukkan hasil *confusion matrix* dengan *accuracy* 99.56%, *precision* 99.13%, *recall* 100%, *f1-score* 99.56%.

D. Perbandingan Hasil Dataset NON-CLAHE dan CLAHE

setelah menguji dua jenis citra, yaitu citra Non-CLAHE dan citra yang telah ditingkatkan kontrasnya menggunakan metode CLAHE. Dilakukan perbandingan antara keduanya, tujuannya adalah untuk mengevaluasi dampak penggunaan CLAHE dalam meningkatkan kualitas citra serta memahami perbedaan antara keduanya dalam konteks pengolahan citra dan analisis visual. CLAHE terbukti meningkatkan akurasi, presisi, dan recall dibandingkan citra Non-CLAHE, menunjukkan bahwa CLAHE efektif dalam meningkatkan performa model pengenalan citra. CLAHE mengatasi kontras rendah yang terlihat pada citra Non-CLAHE, menghasilkan gambar yang lebih tajam dan jelas. Namun, perlu dicatat bahwa penggunaan CLAHE tidak selalu menghasilkan hasil yang lebih baik dalam setiap situasi, dan pengaturan parameter yang tepat sangat penting untuk menghindari peningkatan noise dalam citra. Perbandingan ini menunjukkan bahwa CLAHE lebih cocok untuk citra dengan kontras rendah, terutama dalam bidang citra medis di mana teknik ini dapat sangat berguna untuk meningkatkan visualisasi detail anatomi. Keseluruhan, perbandingan antara citra CLAHE dan asli penting dalam pengambilan keputusan terkait pengolahan citra untuk memilih metode yang paling sesuai dengan tujuan yang diinginkan..



Gambar 11. Grafik Perbandingan Pengujian Non-Clahe dan Clahe

Gambar 11. menampilkan grafik perbandingan dari hasil pengujian model dataset *non-clahe* dan dataset *clahe*. Dari grafik tersebut menunjukkan bahwa model dengan dataset CLAHE memiliki performa tertinggi yaitu, *accuracy* 99.56%, *precision* 99.13%, *recall* 100%, *f1-score* 99.56%.. sedangkan model dengan dataset *non-clahe* menghasilkan performa sedikit lebih rendah yaitu, *accuracy* 98.68%, *precision* 99.55%, *recall* 97.81%, *f1-score* 98.67%.

IV. KESIMPULAN

Klasifikasi citra ginjal normal dan tumor dilakukan menggunakan *CNN MobileNetV2*. Dataset yang digunakan terdiri dari 2.280 CT scan normal dan 2.280 CT scan tumor. Kinerja model dievaluasi menggunakan *confusion matrix* untuk memperoleh nilai *precision*, *recall*, *f1-score*, dan *accuracy*. Hasil percobaan pada dataset *non-clahe* menunjukkan bahwa hasil terbaik diperoleh pada rasio pembagian 80:20 dengan *optimizer Adam* dan *learning rate* 0,01, menghasilkan *f1-score* sebesar 98,67% dan *accuracy* 98,68%. Sementara itu, hasil terbaik dengan data yang telah diproses menggunakan CLAHE diperoleh dengan kombinasi *clip limit* 20 dan *tile grid* 8x8, menggunakan *optimizer Adam* dengan *learning rate* 0,01, menghasilkan *f1-score* sebesar 99,56% dan *accuracy* 99,56%. Dengan demikian, dapat disimpulkan bahwa penggunaan CLAHE meningkatkan performa model dalam mengklasifikasikan citra CT scan.

Hasil ini sangat penting dalam konteks eksperimental karena menunjukkan potensi untuk mendiagnosis tumor ginjal dengan lebih akurat dan efisien, yang dapat meningkatkan hasil diagnosa pasien dan mengurangi risiko kesalahan diagnosa. Hal ini sangat penting bagi ahli radiologi, karena dapat membantu mereka dalam membuat diagnosis yang lebih tepat dan cepat. Disarankan untuk mempertimbangkan penambahan jumlah data citra yang dilatih, variasi kombinasi clip limit dan tile grid, serta eksplorasi penggunaan kombinasi metode peningkatan citra lainnya seperti Contrast Stretching atau Gamma Correction. Penelitian lebih lanjut diperlukan untuk menguji efektivitas model ini dalam kondisi klinis nyata.

REFERENCES

- [1] V. V. Patel, A. R. Yadav, P. Jain, and L. R. Cenkeramaddi, "A Systematic Kidney Tumor Segmentation and Classification Framework using Adaptive and Attentive-based Deep Learning Networks with Improved Crayfish Optimization Algorithm," *IEEE Access*, 2024, doi: 10.1109/ACCESS.2024.3410833.
- [2] L. Corbat, J. Henriët, Y. Chaussy, and J.-C. Lapayre, "Fusion of multiple segmentations of medical images using OV 2 ASSION and Deep Learning methods: Application to CT-Scans for tumoral kidney," 2020.
- [3] World Cancer Research Fund International, "Kidney cancer statistics," <https://www.wcrf.org/cancer-trends/kidney-cancer-statistics/>, 2020. Accessed: May 09, 2024. [Online]. Available: <https://www.wcrf.org/cancer-trends/kidney-cancer-statistics/>
- [4] Z. Riaz, B. Khan, S. Abdullah, S. Khan, and M. S. Islam, "Lung Tumor Image Segmentation from Computer Tomography Images Using MobileNetV2 and Transfer Learning," *Bioengineering*, vol. 10, no. 8, Aug. 2023, doi: 10.3390/bioengineering10080981.
- [5] G. M. Ghiggeri *et al.*, "A two-stage renal disease classification based on transfer learning with hyperparameters optimization," *croatia*, Apr. 2023. doi: 10.3389/fmed.2023.1106717.
- [6] W. Alhazmi and T. Turki, "Applying Deep Transfer Learning to Assess the Impact of Imaging Modalities on Colon Cancer Detection," *Diagnostics*, vol. 13, no. 10, May 2023, doi: 10.3390/diagnostics13101721.
- [7] S. Singh, V. Saxena, and B. Bhimrao, "A Fine Tuned Pre-trained Model for Classification of Brain Tumor using Magnetic Resonance Imaging." [Online]. Available: <https://www.researchgate.net/publication/378240870>
- [8] J. Kers *et al.*, "Deep learning-based classification of kidney transplant pathology: a retrospective, multicentre, proof-of-concept study," *Lancet Digit Health*, vol. 4, no. 1, pp. e18–e26, Jan. 2022, doi: 10.1016/S2589-7500(21)00211-9.
- [9] T. Mahmood, J. Li, Y. Pei, and F. Akhtar, "An automated in-depth feature learning algorithm for breast abnormality prognosis and robust characterization from mammography images using deep transfer learning," *Biology (Basel)*, vol. 10, no. 9, Sep. 2021, doi: 10.3390/biology10090859.
- [10] S. Saifullah and R. Drezewski, "Modified Histogram Equalization for Improved CNN Medical Image Segmentation," in *Procedia Computer Science*, Elsevier B.V., 2023, pp. 3021–3030. doi: 10.1016/j.procs.2023.10.295.
- [11] A. N. Ismael, N. H. Ajam, and Z. S. Jumaa, "Comparative study of Histogram Equalization Enhancement Techniques for Medical Images," *Int J Sci Eng Res*, vol. 10, no. 6, 2019, [Online]. Available: <http://www.ijser.org>

- [12] N. Salem, H. Malik, and A. Shams, "Medical image enhancement based on histogram algorithms," in *Procedia Computer Science*, Elsevier B.V., 2019, pp. 300–311. doi: 10.1016/j.procs.2019.12.112.
- [13] M. Kyriakopoulou, "Histogram Equalization on Medical Images: CLAHE implementation on CT images," Greece, May 2020. Accessed: Jun. 15, 2024. [Online]. Available: <https://eclass.hmu.gr/modules/document/index.php?course=TP283&download=/6069a1b4Lu7B/6069a1cegUDz.pdf>
- [14] M. Faruk and N. Nafi'iyah, "Telematika Klasifikasi Kanker Kulit Berdasarkan Fitur Tekstur, Fitur Warna Citra Menggunakan SVM dan KNN," vol. 13, no. 2, pp. 100–109, 2020, doi: 10.35671/telematika.v13i2.987.
- [15] M. F. Naufal, "Analisis Perbandingan Algoritma SVM, KNN, Dan CNN Untuk Klasifikasi Citra Cuaca", doi: 10.25126/jtiik.202184553.
- [16] F. Aulia *et al.*, "Implementasi Algoritma Convolutional Neural Network untuk Mendeteksi Penyakit Ginjal Implementation Of Convolutional Neural Network For Detecting Kidney Disease." [Online]. Available: <http://jtika.if.unram.ac.id/index.php/JTIKA/>
- [17] D. Gunawan and H. Setiawan, "Convolutional Neural Network dalam Analisis Citra Medis," Dec. 2022.
- [18] D. Abdillah Salafy, F. Yanto, S. Agustian, and F. Insani, "KLIK: Kajian Ilmiah Informatika dan Komputer Perbandingan Klasifikasi Citra CT-Scan Kanker Paru-Paru Menggunakan Image Enhancement CLAHE Pada EfficientNet-B0," *Media Online*, vol. 4, no. 3, pp. 1651–1659, 2023, doi: 10.30865/klik.v4i3.1514.
- [19] A. Salam, F. Yanto, S. Agustian, and S. Ramadhani, "KLIK: Kajian Ilmiah Informatika dan Komputer Perbandingan Klasifikasi Citra CT-Scan Kanker Paru-Paru Menggunakan Contrast Stretching Pada CNN dengan EfficientNet-B0," *Media Online*, vol. 4, no. 3, pp. 1341–1351, 2023, doi: 10.30865/klik.v4i3.1448.
- [20] S. Saifullah, A. Pranolo, and R. Dreżewski, "Comparative Analysis of Image Enhancement Techniques for Brain Tumor Segmentation: Contrast, Histogram, and Hybrid Approaches," Apr. 2024. doi: <https://doi.org/10.1051/e3sconf/202450101020>.
- [21] M. N. Islam, M. Hasan, M. K. Hossain, M. G. R. Alam, M. Z. Uddin, and A. Soylu, "Vision transformer and explainable transfer learning models for auto detection of kidney cyst, stone and tumor from CT-radiography," *Sci Rep*, vol. 12, no. 1, Dec. 2022, doi: 10.1038/s41598-022-15634-4.
- [22] S. Saifullah, "Analisis Perbandingan HE Dan CLAHE pada Image Enhancement dalam Proses Segmenasi Citra Untuk Deteksi Fertilitas Telur," Yogyakarta, Mar. 2020.
- [23] J. W. Gichoya *et al.*, "AI recognition of patient race in medical imaging: a modelling study," *Lancet Digit Health*, vol. 4, no. 6, pp. e406–e414, Jun. 2022, doi: 10.1016/S2589-7500(22)00063-2.
- [24] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen, "MobileNetV2: Inverted Residuals and Linear Bottlenecks," Jan. 2019, doi: <https://doi.org/10.48550/arXiv.1801.04381>.
- [25] F. M. Hana and I. D. Maulida, "Analysis of contrast limited adaptive histogram equalization (CLAHE) parameters on finger knuckle print identification," in *Journal of Physics: Conference Series*, IOP Publishing Ltd, Feb. 2021. doi: 10.1088/1742-6596/1764/1/012049.
- [26] W. Hastomo, A. Satyo Bayangkari Karno, E. Sestri, E. Karla, and D. Arif, "Arsitektur MobilenetV2 Untuk Mendeteksi Citra X-Ray Covid-19," vol. 5, no. 2, pp. 295–303, 2022, doi: 10.31764/justek.vXiY.ZZZ.

- [27] M. Pandiyarajan and R. S. Valarmathi, "Deep Learning Techniques in Classification of Stages in Dementia: An Ensemble Approach," *Journal of Advanced Research in Applied Sciences and Engineering Technology*, vol. 36, no. 1, pp. 131–146, Jun. 2024, doi: 10.37934/araset.36.1.131146.
- [28] A. Tedyyana, O. Ghazali, and O. W. Purbo, "Machine learning for network defense: automated DDoS detection with telegram notification integration," *Indonesian Journal of Electrical Engineering and Computer Science*, vol. 34, no. 2, p. 1102, May 2024, doi: 10.11591/ijeecs.v34.i2.pp1102-1109.